

Fundamentos de Probabilidad y Estadística I: Estadística Descriptiva

Roger Jesús Tovar Falón¹

¹Profesor Titular. Departamento de Matemáticas y Estadística
Universidad de Córdoba

Montería, 2021

Agenda

Introducción

Representación gráfica de datos cualitativos

- Gráfico de barras

- Gráfico circular

Representación gráfica de datos cuantitativos

- Gráfico de puntos

- Gráfico de tallos y hojas

- Distribución de Frecuencias e Histograma

- Polígono de Frecuencias y Densidad

- Ojiva

Medidas de tendencia central y dispersión

- Medidas de tendencia central

- Medidas de dispersión



¿Qué es Estadística?



¿Qué es Estadística?

Es la disciplina que se ocupa de...

Recolección, organización, resumen y análisis de datos con el objetivo de ayudar en la **toma de decisiones** y **resolver problemas**.



¿Qué es Estadística?

Es la disciplina que se ocupa de...

Recolección, organización, resumen y análisis de datos con el objetivo de ayudar en la **toma de decisiones** y **resolver problemas**.

La estadística ayuda a los ingenieros y científicos a:

- ▶ Diseñar nuevos productos y sistemas.
- ▶ Perfeccionar los existentes.
- ▶ Diseñar, desarrollar y mejorar procesos de producción.
- ▶ Aumentar la calidad de los productos,

Necesidad de la estadística

La estadística..

surge de la necesidad de describir y comprender la **variabilidad**.



Necesidad de la estadística

La estadística..

surge de la necesidad de describir y comprender la **variabilidad**.

La variabilidad

Es el resultado de cambios en las condiciones bajo las cuales se hacen las observaciones.

- ▶ Diferencias en las propiedades de los materiales.
- ▶ En la forma que trabajan los obreros.
- ▶ Desgaste y desajuste de la maquinarias.
- ▶ Factores ambientales: humedad, temperatura ambiente, radiación solar.
- ▶ Debido al esquema de muestreo.



Estadística descriptiva

La **estadística descriptiva** es la etapa inicial del análisis, es usado para describir, organizar y resumir los datos recolectados de una forma fácil y rápida.



Estadística descriptiva

La **estadística descriptiva** es la etapa inicial del análisis, es usado para describir, organizar y resumir los datos recolectados de una forma fácil y rápida.

Otras definiciones...

Nos proporciona herramientas para:



Estadística descriptiva

La **estadística descriptiva** es la etapa inicial del análisis, es usado para describir, organizar y resumir los datos recolectados de una forma fácil y rápida.

Otras definiciones...

Nos proporciona herramientas para:

- ▶ Registrar datos.



Estadística descriptiva

La **estadística descriptiva** es la etapa inicial del análisis, es usado para describir, organizar y resumir los datos recolectados de una forma fácil y rápida.

Otras definiciones...

Nos proporciona herramientas para:

- ▶ Registrar datos.
- ▶ Presentar gráficamente grandes conjuntos de datos.



Estadística descriptiva

La **estadística descriptiva** es la etapa inicial del análisis, es usado para describir, organizar y resumir los datos recolectados de una forma fácil y rápida.

Otras definiciones...

Nos proporciona herramientas para:

- ▶ Registrar datos.
- ▶ Presentar gráficamente grandes conjuntos de datos.
- ▶ Resumir los datos a un número (Estadísticas).



Estadística inferencial

Entendemos por **estadística inferencial** al conjunto de técnicas que permite, a partir de datos **muestrales**, sacar conclusiones sobre la **población** de interés, controlando errores a un costo mínimo.



Estadística inferencial

Entendemos por **estadística inferencial** al conjunto de técnicas que permite, a partir de datos **muestrales**, sacar conclusiones sobre la **población** de interés, controlando errores a un costo mínimo.

Otras definiciones...

Ciencia que crea, desarrolla y aplica técnicas de modo que pueda evaluarse la incertidumbre de inferencias inductivas.



Estadística inferencial

La estadística ayuda al investigador a contestar preguntas como:

- ▶ ¿Qué técnicas uso para recolectar datos?



Estadística inferencial

La estadística ayuda al investigador a contestar preguntas como:

- ▶ ¿Qué técnicas uso para recolectar datos?
- ▶ ¿Qué modelos uso para analizar mis datos?



Estadística inferencial

La estadística ayuda al investigador a contestar preguntas como:

- ▶ ¿Qué técnicas uso para recolectar datos?
- ▶ ¿Qué modelos uso para analizar mis datos?
- ▶ ¿Cómo pruebo determinada hipótesis?



Estadística inferencial

La estadística ayuda al investigador a contestar preguntas como:

- ▶ ¿Qué técnicas uso para recolectar datos?
- ▶ ¿Qué modelos uso para analizar mis datos?
- ▶ ¿Cómo pruebo determinada hipótesis?
- ▶ ¿Cómo diseño un experimento de tal forma que los datos obtenidos sean susceptibles de analizar con métodos estadísticos?



Conceptos básicos (I)

Población

Es la colección completa de todas las observaciones que son de interés en un momento particular para el investigador.



Conceptos básicos (I)

Población

Es la colección completa de todas las observaciones que son de interés en un momento particular para el investigador.

Parámetro

Medida descriptiva de la población total de las observaciones de interés para el investigador.



Conceptos básicos (II)

Muestra

Es una parte (subconjunto) “representativa” de la población que se selecciona para ser estudiada, ya que la población es demasiado grande como para analizarla en su totalidad.



Conceptos básicos (II)

Muestra

Es una parte (subconjunto) “representativa” de la población que se selecciona para ser estudiada, ya que la población es demasiado grande como para analizarla en su totalidad.

Estadística

Valor que describe una muestra y sirve como estimación de un parámetro de la población correspondiente.

Conceptos básicos (III)

Variable

Característica de la población que se estudia.

Conceptos básicos (III)

Variable

Característica de la población que se estudia.

Clasificación

1. Cualitativas: Se miden de manera no numérica.

- ▶ Sexo,
- ▶ Color de ojos, Preferencias.
- ▶ Tipo de sangre, Estado civil.
- ▶ Grado de escolaridad.



Conceptos básicos (III)

Variable

Característica de la población que se estudia.

Clasificación

1. Cualitativas: Se miden de manera no numérica.
 - ▶ Sexo,
 - ▶ Color de ojos, Preferencias.
 - ▶ Tipo de sangre, Estado civil.
 - ▶ Grado de escolaridad.
2. Cuantitativas: Pueden expresarse numéricamente.
 - ▶ Peso, altura, salario, edad,
 - ▶ Presión, temperatura, masas, pesos.
 - ▶ Número de hijos, número de carros.
 - ▶ Cantidad de fisuras en un material.

Variables cuantitativas

Clasificación de las variables cuantitativas

1. Discretas: los valores se limitan a números enteros, por lo general son el resultado de conteos.
 - ▶ Cantidad de hijos de una familia.
 - ▶ Número de defectos de una pieza.
 - ▶ Cantidad de fisuras en un material.
 - ▶ Número de accidentes en un cruce durante el fin de semana.
 - ▶ Número de pacientes que superan una enfermedad.



Variables cuantitativas

Clasificación de las variables cuantitativas

1. Discretas: los valores se limitan a números enteros, por lo general son el resultado de conteos.
 - ▶ Cantidad de hijos de una familia.
 - ▶ Número de defectos de una pieza.
 - ▶ Cantidad de fisuras en un material.
 - ▶ Número de accidentes en un cruce durante el fin de semana.
 - ▶ Número de pacientes que superan una enfermedad.
2. Contínuas: puede tomar cualquier valor dentro de un rango numérico.
 - ▶ Temperatura, presión, tiempo.
 - ▶ Longitudes, distancias, masas, pesos



Barras simples

Ejemplo

En una escala de 1 a 4, siendo 4 el mejor, un grupo de consumidores clasifica la “responsabilidad social empresarial” de 50 organizaciones clasificadas como públicas (= 1), privadas (= 2), o controladas por el gobierno (= 3),

Barras simples

Ejemplo

En una escala de 1 a 4, siendo 4 el mejor, un grupo de consumidores clasifica la “responsabilidad social empresarial” de 50 organizaciones clasificadas como públicas (= 1), privadas (= 2), o controladas por el gobierno (= 3),

Organización	Tipo	Clasificación
1	1	1
2	2	2
3	2	3
⋮	⋮	⋮
49	1	2
50	2	1


Tabla de contingencia

Tipo	Clasificación				Total
	1	2	3	4	
1	7	5	1	2	15
2	3	7	5	4	19
3	3	5	4	4	16
Total	13	17	10	10	50


Tabla de contingencia

Tipo	Clasificación				Total
	1	2	3	4	
1	7	5	1	2	15
2	3	7	5	4	19
3	3	5	4	4	16
Total	13	17	10	10	50


Barras Simples



Barras Apliadas



Barras Apliadas



Barras Múltiples




Diagrama circular

Se basa en una proporcionalidad entre la frecuencia y el ángulo central de una circunferencia, de tal manera que a la frecuencia total le corresponde el ángulo central de 360 grados.

El ángulo se determina por

$$\theta_i = \frac{f_i \times 360}{\sum f_i}$$

donde f_i es la frecuencia de la i -ésima categoría.

Diagrama circular

Se basa en una proporcionalidad entre la frecuencia y el ángulo central de una circunferencia, de tal manera que a la frecuencia total le corresponde el ángulo central de 360 grados.

El ángulo se determina por

$$\theta_i = \frac{f_i \times 360}{\sum f_i}$$

donde f_i es la frecuencia de la i -ésima categoría.

Tipo	f_i	θ_i
Públicas	15	108.0
Privadas	19	136.8
Controladas	16	115.2




Diagrama de puntos

Un ingeniero agrega un polímero de látex a un mortero de cemento portland, para determinar el efecto del polímero sobre la resistencia a la tensión (en $\text{kgf} = \text{cm}^2$). La tabla muestra los datos del mortero modificado (exp1) y del mortero sin modificar (exp2).



Diagrama de puntos

Un ingeniero agrega un polímero de látex a un mortero de cemento portland, para determinar el efecto del polímero sobre la resistencia a la tensión (en $\text{kgf} = \text{cm}^2$). La tabla muestra los datos del mortero modificado (exp1) y del mortero sin modificar (exp2).

	1	2	3	4	5	6	7	8	9	10
exp1	16.85	16.40	17.21	16.35	16.52	17.04	16.96	17.15	16.59	16.57
exp2	17.50	17.63	18.25	18.00	17.86	17.75	18.22	17.90	17.96	18.15

Diagrama de puntos




Diagrama de tallos y hojas

Una nueva aleación de aluminio litio está siendo evaluada como posible material para la fabricación de elementos estructurales de aeronaves. Los datos de resistencia a la tensión, en libras por pulgada cuadrada (psi), de 80 muestras se transcriben en la siguiente tabla..

Diagrama de tallos y hojas

Una nueva aleación de aluminio litio está siendo evaluada como posible material para la fabricación de elementos estructurales de aeronaves. Los datos de resistencia a la tensión, en libras por pulgada cuadrada (psi), de 80 muestras se transcriben en la siguiente tabla..

105	97	245	163	207	134	218	199	160	196
221	154	228	131	180	178	157	151	175	201
183	153	174	154	190	76	101	142	149	200
186	174	199	115	193	167	171	163	87	176
121	120	181	160	194	184	165	145	160	150
181	168	158	208	133	135	172	171	237	170
180	167	176	158	156	229	158	148	150	118
143	141	110	133	123	146	169	158	135	149

Diagrama de tallos y hojas

	n:	80
1	7	6
2	8	7
3	9	7
5	10	15
8	11	058
11	12	013
17	13	133455
25	14	12356899
37	15	001344678888
(10)	16	0003357789
33	17	0112445668
23	18	0011346
16	19	034699
10	20	0178
6	21	8
5	22	189
2	23	7
1	24	5

Diagrama de tallos y hojas

n: 80		
1	7	6
2	8	7
3	9	7
5	10	15
8	11	058
11	12	013
17	13	133455
25	14	12356899
37	15	001344678888
(10)	16	0003357789
33	17	0112445668
23	18	0011346
16	19	034699
10	20	0178
6	21	8
5	22	189
2	23	7
1	24	5

- 75 muestras (94 %) resistieron 110 psi o más.

Diagrama de tallos y hojas

	n:	80
1	7	6
2	8	7
3	9	7
5	10	15
8	11	058
11	12	013
17	13	133455
25	14	12356899
37	15	001344678888
(10)	16	0003357789
33	17	0112445668
23	18	0011346
16	19	034699
10	20	0178
6	21	8
5	22	189
2	23	7
1	24	5

- ▶ 75 muestras (94 %) resistieron 110 psi o más.
- ▶ El valor central está en un punto alrededor de 150 y 170 psi.

Diagrama de tallos y hojas

n: 80		
1	7	6
2	8	7
3	9	7
5	10	15
8	11	058
11	12	013
17	13	133455
25	14	12356899
37	15	001344678888
(10)	16	0003357789
33	17	0112445668
23	18	0011346
16	19	034699
10	20	0178
6	21	8
5	22	189
2	23	7
1	24	5

- ▶ 75 muestras (94 %) resistieron 110 psi o más.
- ▶ El valor central está en un punto alrededor de 150 y 170 psi.
- ▶ La mediana es un valor entre 160 y 169 psi.

Diagrama de tallos y hojas

n: 80		
1	7	6
2	8	7
3	9	7
5	10	15
8	11	058
11	12	013
17	13	133455
25	14	12356899
37	15	001344678888
(10)	16	0003357789
33	17	0112445668
23	18	0011346
16	19	034699
10	20	0178
6	21	8
5	22	189
2	23	7
1	24	5


- ▶ 75 muestras (94 %) resistieron 110 psi o más.
- ▶ El valor central está en un punto alrededor de 150 y 170 psi.
- ▶ La mediana es un valor entre 160 y 169 psi.
- ▶ 8 muestras fallaron por debajo de los 120 psi.

Diagrama de tallos y hojas

n: 80		
1	7	6
2	8	7
3	9	7
5	10	15
8	11	058
11	12	013
17	13	133455
25	14	12356899
37	15	001344678888
(10)	16	0003357789
33	17	0112445668
23	18	0011346
16	19	034699
10	20	0178
6	21	8
5	22	189
2	23	7
1	24	5

- ▶ 75 muestras (94 %) resistieron 110 psi o más.
- ▶ El valor central está en un punto alrededor de 150 y 170 psi.
- ▶ La mediana es un valor entre 160 y 169 psi.
- ▶ 8 muestras fallaron por debajo de los 120 psi.
- ▶ Sólo 6 muestras resistieron mas de 210 psi.

Distribución de frecuencia e histograma





Distribución de frecuencia e histograma

Inf	Sup	M_i	f_i	fr_i	F_i	Fr_i
70	90	80	2	0.0250	2	0.0250
90	110	100	3	0.0375	5	0.0625
110	130	120	6	0.0750	11	0.1375
130	150	140	14	0.1750	25	0.3125
150	170	160	22	0.2750	47	0.5875
170	190	180	17	0.2125	64	0.8000
190	210	200	10	0.1250	74	0.9250
210	230	220	4	0.0500	78	0.9750
230	250	240	2	0.0250	80	1.0000
			80	1		

Distribución de frecuencia e histograma

¿Cuántos intervalos de clase?

1. Depende del número de observaciones.

Distribución de frecuencia e histograma

¿Cuántos intervalos de clase?

1. Depende del número de observaciones.
2. Resulta satisfactorio entre 5 y 20 clases.

Distribución de frecuencia e histograma

¿Cuántos intervalos de clase?

1. Depende del número de observaciones.
2. Resulta satisfactorio entre 5 y 20 clases.
3. Algunas fórmulas empíricas:
 - ▶ $K \approx \sqrt{n}$, con $n = 80$ se tiene $\sqrt{80} = 8.94 \approx 9$

Distribución de frecuencia e histograma

¿Cuántos intervalos de clase?


1. Depende del número de observaciones.
2. Resulta satisfactorio entre 5 y 20 clases.
3. Algunas fórmulas empíricas:
 - ▶ $K \approx \sqrt{n}$, con $n = 80$ se tiene $\sqrt{80} = 8.94 \approx 9$
 - ▶ $K \approx 1 + 3.3 \log_{10}(n)$ (Fórmula de Sturges). Para el ejemplo, $1 + 3.3 \log_{10}(80) = 7,28 \approx 7$

Distribución de frecuencia e histograma


¿Cuántos intervalos de clase?

1. Depende del número de observaciones.
2. Resulta satisfactorio entre 5 y 20 clases.
3. Algunas fórmulas empíricas:
 - ▶ $K \approx \sqrt{n}$, con $n = 80$ se tiene $\sqrt{80} = 8.94 \approx 9$
 - ▶ $K \approx 1 + 3.3 \log_{10}(n)$ (Fórmula de Sturges). Para el ejemplo, $1 + 3.3 \log_{10}(80) = 7,28 \approx 7$
 - ▶ $K \approx \frac{\ln(n)}{\ln(2)}$, para el ejemplo $\frac{\ln(80)}{\ln(2)} = 6.32 \approx 7$


Polígono de Frecuencias




Polígono de Frecuencias



Función de Densidad



Ojiva



Media aritmética.

Definición

La **media aritmética** de un conjunto de n observaciones $y_1, y_2, \dots, y_n$ es igual a la suma de las observaciones dividida por n (el número de datos). Se indica con $\bar{y}$.

Media aritmética.

Definición

La **media aritmética** de un conjunto de n observaciones $y_1, y_2, \dots, y_n$ es igual a la suma de las observaciones dividida por n (el número de datos). Se indica con $\bar{y}$.

$$\bar{y} = \frac{y_1 + y_2 + \dots + y_n}{n} = \frac{\sum_{i=1}^n y_i}{n}$$

Media aritmética.

Ejemplo: Considere las siguientes 15 mediciones

8	10	4	3	8
5	6	8	7	6
7	7	5	11	7

Media aritmética.

Ejemplo: Considere las siguientes 15 mediciones

8	10	4	3	8
5	6	8	7	6
7	7	5	11	7

Cálculo de la media

$$\bar{y} = \frac{8 + 5 + 7 + \cdots + 6 + 7}{15} = \frac{102}{15} = 6.8$$



Media aritmética (Datos agrupados).

¿Cómo se calcula?

$$\bar{x}_a = \frac{\sum_{i=1}^K f_i M_i}{n}$$

- ▶ f_i es la frecuencia de clase
- ▶ M_i es la marca de clase
- ▶ n es el número de datos



Media aritmética (Datos agrupados).

¿Cómo se calcula?

$$\bar{x}_a = \frac{\sum_{i=1}^K f_i M_i}{n}$$

- ▶ f_i es la frecuencia de clase
- ▶ M_i es la marca de clase
- ▶ n es el número de datos

Ejemplo: Calcular la media a partir de los datos agrupados del ejemplo de resistencia a la tensión.

$$\bar{x}_a = \frac{2 \times 80 + 3 \times 100 + \cdots + 4 \times 220 + 2 \times 240}{80} = \frac{13080}{80} = 163.5$$



Mediana.

Definición

La **mediana** de un conjunto de valores $y_1, y_2, \dots, y_n$ es el valor tal que la mitad de las observaciones son menores o iguales que él y la otra mitad es mayor o igual que él.

Mediana.

Definición

La **mediana** de un conjunto de valores $y_1, y_2, \dots, y_n$ es el valor tal que la mitad de las observaciones son menores o iguales que él y la otra mitad es mayor o igual que él.

Si $y_{(1)}, y_{(2)}, \dots, y_{(n)}$ es una muestra acomodada en orden creciente de magnitud. La mediana se define como la observación que ocupa el lugar $\frac{n+1}{2}$. Si n es impar, o el promedio de las observaciones que ocupan los lugares $\frac{n}{2}$ e $\frac{n}{2} + 1$ si n es par.

Mediana.

Definición

La **mediana** de un conjunto de valores $y_1, y_2, \dots, y_n$ es el valor tal que la mitad de las observaciones son menores o iguales que él y la otra mitad es mayor o igual que él.

Si $y_{(1)}, y_{(2)}, \dots, y_{(n)}$ es una muestra acomodada en orden creciente de magnitud. La mediana se define como la observación que ocupa el lugar $\frac{n+1}{2}$. Si n es impar, o el promedio de las observaciones que ocupan los lugares $\frac{n}{2}$ e $\frac{n}{2} + 1$ si n es par.

$$M_e = \begin{cases} y_{(\frac{n+1}{2})}, & \text{si } n \text{ es impar,} \\ \frac{y_{(\frac{n}{2})} + y_{(\frac{n}{2}+1)}}{2}, & \text{si } n \text{ es par,} \end{cases}$$



Mediana (Ejemplos).

1. Obtener la mediana de 8, 3, 2, 4, 5, 6, 9.



Mediana (Ejemplos).

1. Obtener la mediana de 8, 3, 2, 4, 5, 6, 9.

$n = 7$ es un número impar, la mediana es la observación que ocupa el lugar $\frac{7+1}{2} = 4$ después de ordenar los datos

Posición	1	2	3	4	5	6	7
Dato	2	3	4	5	6	8	9

Mediana (Ejemplos).

1. Obtener la mediana de 8, 3, 2, 4, 5, 6, 9.

$n = 7$ es un número impar, la mediana es la observación que ocupa el lugar $\frac{7+1}{2} = 4$ después de ordenar los datos

Posición	1	2	3	4	5	6	7
Dato	2	3	4	5	6	8	9

$$M_e = 5$$



Mediana (Ejemplos).

1. Obtener la mediana de 8, 3, 2, 4, 5, 6, 9.

$n = 7$ es un número impar, la mediana es la observación que ocupa el lugar $\frac{7+1}{2} = 4$ después de ordenar los datos

Posición	1	2	3	4	5	6	7
Dato	2	3	4	5	6	8	9

$$M_e = 5$$

2. Obtener la mediana de 9, 2, 7, 11, 14, 6.



Mediana (Ejemplos).

1. Obtener la mediana de 8, 3, 2, 4, 5, 6, 9.

$n = 7$ es un número impar, la mediana es la observación que ocupa el lugar $\frac{7+1}{2} = 4$ después de ordenar los datos

Posición	1	2	3	4	5	6	7
Dato	2	3	4	5	6	8	9

$$M_e = 5$$

2. Obtener la mediana de 9, 2, 7, 11, 14, 6.

$n = 6$ es un número par, la mediana es el promedio de las observaciones que ocupan los lugares $\frac{6}{2} = 3$ y $\frac{6}{2} + 1 = 4$ después de ordenar los datos

Posición	1	2	3	4	5	6
Dato	2	6	7	9	11	14



Mediana (Ejemplos).

1. Obtener la mediana de 8, 3, 2, 4, 5, 6, 9.

$n = 7$ es un número impar, la mediana es la observación que ocupa el lugar $\frac{7+1}{2} = 4$ después de ordenar los datos

Posición	1	2	3	4	5	6	7
Dato	2	3	4	5	6	8	9

$$M_e = 5$$

2. Obtener la mediana de 9, 2, 7, 11, 14, 6.

$n = 6$ es un número par, la mediana es el promedio de las observaciones que ocupan los lugares $\frac{6}{2} = 3$ y $\frac{6}{2} + 1 = 4$ después de ordenar los datos

Posición	1	2	3	4	5	6
Dato	2	6	7	9	11	14

$$M_e = \frac{7+9}{2} = 8$$

Mediana (Ventaja).

Robusta a valores extremos

La mediana tiene la ventaja que los valores extremos no tienen influencia sobre ella.

Mediana (Ventaja).

Robusta a valores extremos

La mediana tiene la ventaja que los valores extremos no tienen influencia sobre ella.

1. Suponga las siguientes observaciones: 1, 3, 4, 2, 7, 6 y 8. La media es 4.43, mientras que **la mediana es 4**. Ambas cantidades proporcionan una medida razonable de la tendencia central de los datos.



Mediana (Ventaja).

Robusta a valores extremos

La mediana tiene la ventaja que los valores extremos no tienen influencia sobre ella.

1. Suponga las siguientes observaciones: 1, 3, 4, 2, 7, 6 y 8. La media es 4.43, mientras que **la mediana es 4**. Ambas cantidades proporcionan una medida razonable de la tendencia central de los datos.
2. Suponga ahora que los datos son 1, 3, 4, 2, 7, 2450 y 8. La mediana sigue siendo 4, pero **la media es 353.57** que no dice mucho respecto a la tendencia central de los datos.

La media no es suficiente

Considere los siguientes datos:

Muestra 1	130	150	145	158	165	140
Muestra 2	90	128	205	140	165	160

La media no es suficiente

Considere los siguientes datos:

Muestra 1	130	150	145	158	165	140
Muestra 2	90	128	205	140	165	160

- Ambas muestras tienen media 148, es decir, $\bar{x}_1 = \bar{x}_2 = 148$.

La media no es suficiente

Considere los siguientes datos:

Muestra 1	130	150	145	158	165	140
Muestra 2	90	128	205	140	165	160

- ▶ Ambas muestras tienen media 148, es decir, $\bar{x}_1 = \bar{x}_2 = 148$.
- ▶ ¿Son similares los dos conjuntos de datos?




La media no es suficiente

Considere los siguientes datos:

Muestra 1	130	150	145	158	165	140
Muestra 2	90	128	205	140	165	160

- ▶ Ambas muestras tienen media 148, es decir, $\bar{x}_1 = \bar{x}_2 = 148$.
- ▶ ¿Son similares los dos conjuntos de datos?
- ▶ La **dispersión** o variabilidad de la muestra 2 es mayor.

La media no es suficiente





Medidas de dispersión

Rango

Diferencia entre la observación mas grande y la mas pequeña.

$$r = \max(y_i) - \min(y_i)$$

Rango de la primera muestra: $r_1 = 165 - 130 = 35$ Rango de la segunda muestra: $r_2 = 205 - 90 = 115$



Medidas de dispersión

Rango

Diferencia entre la observación mas grande y la mas pequeña.

$$r = \max(y_i) - \min(y_i)$$

Rango de la primera muestra: $r_1 = 165 - 130 = 35$ Rango de la segunda muestra: $r_2 = 205 - 90 = 115$

Ignora la información que hay entre el máximo y el mínimo.

Muestra 1	1	3	5	8	9
Muestra 2	1	5	5	5	9

$r_1 = r_2 = 8$. Se requiere una medida que dependa de todas las observaciones (que use toda la información)

Varianza y desviación estándar

Varianza

$$S^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}$$

Varianza y desviación estándar

Varianza

$$S^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}$$

Desviación estándar

La desviación estándar muestral, S , es la raíz cuadrada positiva de la varianza.

$$S = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}$$

Varianza y desviación estándar (Ejemplo)

Calcular la varianza y la desviación estándar de los siguientes datos:

5 8 4 7 6

1. (**Varianza**) Para estos datos tenemos que $n = 5$ y $\bar{y} = 6$

$$\begin{aligned} S^2 &= \frac{(5 - 6)^2 + (8 - 6)^2 + (4 - 6)^2 + (7 - 6)^2 + (6 - 6)^2}{4} \\ &= \frac{(-1)^2 + 2^2 + (-2)^2 + 1^2 + 0^2}{4} = \frac{10}{4} = 2.5 \end{aligned}$$

2. (**Desviación Estándar**) $S = \sqrt{S^2} = \sqrt{2,5} = 1,58$

Varianza (Fórmula Alternativa)

Una fórmula alternativa para calcular la varianza es

$$S^2 = \frac{\sum_{i=1}^n y_i^2 - n\bar{y}^2}{n - 1}$$

Varianza (Fórmula Alternativa)

Una fórmula alternativa para calcular la varianza es

$$S^2 = \frac{\sum_{i=1}^n y_i^2 - n\bar{y}^2}{n - 1}$$

i	y_i	y_i^2
1	5	25
2	8	64
3	4	16
4	7	49
5	6	36
Sumas	30	190

Varianza (Fórmula Alternativa)

Una fórmula alternativa para calcular la varianza es

$$S^2 = \frac{\sum_{i=1}^n y_i^2 - n\bar{y}^2}{n - 1}$$

i	y_i	y_i^2
1	5	25
2	8	64
3	4	16
4	7	49
5	6	36
Sumas	30	190

$$S^2 = \frac{190 - 5 \times 6^2}{4} = \frac{10}{4} = 2.5$$

Varianza (Datos agrupados)

Varianza

$$S_a^2 = \frac{\sum_{i=1}^K f_i M_i^2 - n \bar{x}_a^2}{n - 1}$$

Varianza (Datos agrupados)

Varianza

$$S_a^2 = \frac{\sum_{i=1}^K f_i M_i^2 - n \bar{x}_a^2}{n - 1}$$

- f_i es la frecuencia de clase.

Varianza (Datos agrupados)

Varianza

$$S_a^2 = \frac{\sum_{i=1}^K f_i M_i^2 - n \bar{x}_a^2}{n - 1}$$

- ▶ f_i es la frecuencia de clase.
- ▶ M_i es la marca de clase.

Varianza (Datos agrupados)

Varianza

$$S_a^2 = \frac{\sum_{i=1}^K f_i M_i^2 - n \bar{x}_a^2}{n - 1}$$

- ▶ f_i es la frecuencia de clase.
- ▶ M_i es la marca de clase.
- ▶ n es el número de datos.

Varianza (Datos agrupados)

Varianza

$$S_a^2 = \frac{\sum_{i=1}^K f_i M_i^2 - n \bar{x}_a^2}{n - 1}$$

- ▶ f_i es la frecuencia de clase.
- ▶ M_i es la marca de clase.
- ▶ n es el número de datos.
- ▶ $\bar{x}_a$ es la media calculada a partir de los datos agrupados.

Varianza (Datos agrupados)

Varianza

$$S_a^2 = \frac{\sum_{i=1}^K f_i M_i^2 - n \bar{x}_a^2}{n - 1}$$

- ▶ f_i es la frecuencia de clase.
- ▶ M_i es la marca de clase.
- ▶ n es el número de datos.
- ▶ $\bar{x}_a$ es la media calculada a partir de los datos agrupados.

Ejemplo: Datos del ejemplo de resistencia a la tensión.



Varianza (Datos agrupados)

Varianza

$$S_a^2 = \frac{\sum_{i=1}^K f_i M_i^2 - n \bar{x}_a^2}{n - 1}$$

- ▶ f_i es la frecuencia de clase.
- ▶ M_i es la marca de clase.
- ▶ n es el número de datos.
- ▶ $\bar{x}_a$ es la media calculada a partir de los datos agrupados.

Ejemplo: Datos del ejemplo de resistencia a la tensión.

$$\begin{aligned} S_a^2 &= \frac{(2 \times 80^2 + 3 \times 100^2 + \cdots + 4 \times 220^2 + 2 \times 240^2) - 80 \times 163,5^2}{80 - 1} \\ &= \frac{2226400 - 2138580}{79} = \frac{87820}{79} = 1111.646 \end{aligned}$$

Percentiles y cuartiles

- El **primer cuartil** o cuartil inferior, notado como Q_1 , es un valor tal que el 25 % de los datos es menor o igual que él y el restante 75 % es mayor igual que él.



Percentiles y cuartiles

- ▶ El **primer cuartil** o cuartil inferior, notado como Q_1 , es un valor tal que el 25 % de los datos es menor o igual que él y el restante 75 % es mayor igual que él.
- ▶ El **tercer cuartil**, notado como Q_3 , es un valor que tiene el 75 % de los datos por debajo y él 25 % por encima.

Percentiles y cuartiles

- ▶ El **primer cuartil** o cuartil inferior, notado como Q_1 , es un valor tal que el 25 % de los datos es menor o igual que él y el restante 75 % es mayor igual que él.
- ▶ El **tercer cuartil**, notado como Q_3 , es un valor que tiene el 75 % de los datos por debajo y él 25 % por encima.
- ▶ Cuando un conjunto de datos se divide en cien partes iguales, los puntos de división reciben el nombre de **percentiles**.

Percentiles y cuartiles

- ▶ El **primer cuartil** o cuartil inferior, notado como Q_1 , es un valor tal que el 25 % de los datos es menor o igual que él y el restante 75 % es mayor igual que él.
- ▶ El **tercer cuartil**, notado como Q_3 , es un valor que tiene el 75 % de los datos por debajo y él 25 % por encima.
- ▶ Cuando un conjunto de datos se divide en cien partes iguales, los puntos de división reciben el nombre de **percentiles**.
- ▶ Los **deciles** separan un conjunto de datos en 10 subconjuntos iguales.



Percentiles y cuartiles

- ▶ El **primer cuartil** o cuartil inferior, notado como Q_1 , es un valor tal que el 25 % de los datos es menor o igual que él y el restante 75 % es mayor igual que él.
- ▶ El **tercer cuartil**, notado como Q_3 , es un valor que tiene el 75 % de los datos por debajo y él 25 % por encima.
- ▶ Cuando un conjunto de datos se divide en cien partes iguales, los puntos de división reciben el nombre de **percentiles**.
- ▶ Los **deciles** separan un conjunto de datos en 10 subconjuntos iguales.
- ▶ Los **percentiles** separan un conjunto de datos en 100 subconjuntos iguales.



Percentiles

Definición (Percentiles)

El $100k$ -ésimo percentil ($0 < k < 1$), denotado por P_k es un valor tal que al menos un $100k\%$ de las observaciones son menores o iguales que él y al menos el $100(1 - k)\%$ de las observaciones son mayores o iguales que él. Nótese que $Q_1 = P_{25}$, $Me = Q_2 = P_{50}$ y $Q_3 = P_{75}$.

1. Ordene los datos de menor a mayor,
2. Calcule nk , donde n es el número de datos
 - 2.1 Si nk no es un número entero, aproxímelo al entero siguiente y esa es la posición del percentil $100k\%$
 - 2.2 Si nk es un número entero, el percentil $100k\%$ se obtiene promediando las observaciones que ocupan los lugares nk y $nk + 1$.



Ejemplo

La demanda diaria, en kilogramos, de un producto industrial durante 30 días fue:

38	35	76	58	48	59
67	63	33	69	53	51
28	25	36	32	61	57
49	78	48	42	72	52
47	66	58	44	44	56



Ejemplo

La demanda diaria, en kilogramos, de un producto industrial durante 30 días fue:

38	35	76	58	48	59
67	63	33	69	53	51
28	25	36	32	61	57
49	78	48	42	72	52
47	66	58	44	44	56

Calcule:

- Los cuartiles.



Ejemplo

La demanda diaria, en kilogramos, de un producto industrial durante 30 días fue:

38	35	76	58	48	59
67	63	33	69	53	51
28	25	36	32	61	57
49	78	48	42	72	52
47	66	58	44	44	56

Calcule:

- ▶ Los cuartiles.
- ▶ El percentil 15.



Ejemplo

La demanda diaria, en kilogramos, de un producto industrial durante 30 días fue:

38	35	76	58	48	59
67	63	33	69	53	51
28	25	36	32	61	57
49	78	48	42	72	52
47	66	58	44	44	56

Calcule:

- ▶ Los cuartiles.
- ▶ El percentil 15.
- ▶ El percentil 80.



Ejemplo (Solución)

- Ordenamos los datos

25	28	32	33	35	36
38	42	44	44	47	48
48	49	51	52	53	56
57	58	58	59	61	63
66	67	69	72	76	78



Ejemplo (Solución)

- Ordenamos los datos

25	28	32	33	35	36
38	42	44	44	47	48
48	49	51	52	53	56
57	58	58	59	61	63
66	67	69	72	76	78

- El primer cuartil es el percentil 25, por tanto $k = 25/100 = 0.25$ y $nk = 7.5$ que no es entero, por tanto, lo aproximamos al entero siguiente que es 8, luego $P_{25} = Q_1 = 42$.



Ejemplo (Solución)

- Ordenamos los datos

25	28	32	33	35	36
38	42	44	44	47	48
48	49	51	52	53	56
57	58	58	59	61	63
66	67	69	72	76	78

- El primer cuartil es el percentil 25, por tanto $k = 25/100 = 0.25$ y $nk = 7.5$ que no es entero, por tanto, lo aproximamos al entero siguiente que es 8, luego $P_{25} = Q_1 = 42$.
- El segundo cuartil es el percentil 50 o la mediana de los datos, en este caso $k = 0.5$ y $nk = 15$, el percentil 50 o mediana es el promedio de las observaciones que ocupan los lugares 15 y 16 es decir $(51 + 52)/2 = 51.5$



Ejemplo (Solución)

- El tercer cuartil es el percentil 75, por tanto $k = 0.75$ y $nk = 22.5$, lo aproximamos al entero siguiente que es 23, luego $P_{75} = Q_3 = 61$ ya que esta es la observación que ocupa el lugar 23 en los datos ordenados.



Ejemplo (Solución)

- ▶ El tercer cuartil es el percentil 75, por tanto $k = 0.75$ y $nk = 22.5$, lo aproximamos al entero siguiente que es 23, luego $P_{75} = Q_3 = 61$ ya que esta es la observación que ocupa el lugar 23 en los datos ordenados.
- ▶ Para calcular el percentil 15 se tiene $nk = 30 \times 0.15 = 4.5$ que no es entero y por tanto, $P_{15} = 35$ que es la observación que ocupa el lugar 5 en los datos ordenados.



Ejemplo (Solución)

- ▶ El tercer cuartil es el percentil 75, por tanto $k = 0.75$ y $nk = 22.5$, lo aproximamos al entero siguiente que es 23, luego $P_{75} = Q_3 = 61$ ya que esta es la observación que ocupa el lugar 23 en los datos ordenados.
- ▶ Para calcular el percentil 15 se tiene $nk = 30 \times 0.15 = 4.5$ que no es entero y por tanto, $P_{15} = 35$ que es la observación que ocupa el lugar 5 en los datos ordenados.
- ▶ Para calcular el percentil 80 se tiene $nk = 30 \times 0.8 = 24$ que es entero y por tanto, $P_{80} = (63 + 66)/2 = 64.5$ ya que 63 y 66 son las observaciones que ocupan los lugares 24 y 25 en los datos ordenados. ¿cómo se interpreta este valor?



Gráfico Boxplot

- Facilita la lectura sobre localización, variabilidad, simetría y presencia de datos atípicos.

Gráfico Boxplot

- ▶ Facilita la lectura sobre localización, variabilidad, simetría y presencia de datos atípicos.
- ▶ El boxplot consiste en una caja y guiones con una línea a través de la caja que representa la mediana (segundo cuartil Q_2).



Gráfico Boxplot

- ▶ Facilita la lectura sobre localización, variabilidad, simetría y presencia de datos atípicos.
- ▶ El boxplot consiste en una caja y guiones con una línea a través de la caja que representa la mediana (segundo cuartil Q_2).
- ▶ El extremo inferior de la caja es el primer cuartil Q_1
- ▶ El extremo superior es el tercer cuartil Q_3 .



Gráfico Boxplot

- ▶ Facilita la lectura sobre localización, variabilidad, simetría y presencia de datos atípicos.
- ▶ El boxplot consiste en una caja y guiones con una línea a través de la caja que representa la mediana (segundo cuartil Q_2).
- ▶ El extremo inferior de la caja es el primer cuartil Q_1
- ▶ El extremo superior es el tercer cuartil Q_3 .
- ▶ El bigote superior se extiende desde el tercer cuartil hasta la observación más grande que es menor o igual que $Q_3 + 1.5 \times (Q_3 - Q_1)$.



Gráfico Boxplot

- ▶ Facilita la lectura sobre localización, variabilidad, simetría y presencia de datos atípicos.
- ▶ El boxplot consiste en una caja y guiones con una línea a través de la caja que representa la mediana (segundo cuartil Q_2).
- ▶ El extremo inferior de la caja es el primer cuartil Q_1
- ▶ El extremo superior es el tercer cuartil Q_3 .
- ▶ El bigote superior se extiende desde el tercer cuartil hasta la observación más grande que es menor o igual que $Q_3 + 1.5 \times (Q_3 - Q_1)$.
- ▶ El bigote inferior se extiende hasta la observación más pequeña que es mayor o igual que $Q_3 - 1.5 \times (Q_3 - Q_1)$.



Gráfico Boxplot

- ▶ Facilita la lectura sobre localización, variabilidad, simetría y presencia de datos atípicos.
- ▶ El boxplot consiste en una caja y guiones con una línea a través de la caja que representa la mediana (segundo cuartil Q_2).
- ▶ El extremo inferior de la caja es el primer cuartil Q_1
- ▶ El extremo superior es el tercer cuartil Q_3 .
- ▶ El bigote superior se extiende desde el tercer cuartil hasta la observación más grande que es menor o igual que $Q_3 + 1.5 \times (Q_3 - Q_1)$.
- ▶ El bigote inferior se extiende hasta la observación más pequeña que es mayor o igual que $Q_3 - 1.5 \times (Q_3 - Q_1)$.
- ▶ Las observaciones que estén por fuera de estos límites se clasifican como datos atípicos y se ubican en el diagrama.



Gráfico Boxplot

- ▶ Facilita la lectura sobre localización, variabilidad, simetría y presencia de datos atípicos.
- ▶ El boxplot consiste en una caja y guiones con una línea a través de la caja que representa la mediana (segundo cuartil Q_2).
- ▶ El extremo inferior de la caja es el primer cuartil Q_1
- ▶ El extremo superior es el tercer cuartil Q_3 .
- ▶ El bigote superior se extiende desde el tercer cuartil hasta la observación más grande que es menor o igual que $Q_3 + 1.5 \times (Q_3 - Q_1)$.
- ▶ El bigote inferior se extiende hasta la observación más pequeña que es mayor o igual que $Q_3 - 1.5 \times (Q_3 - Q_1)$.
- ▶ Las observaciones que estén por fuera de estos límites se clasifican como datos atípicos y se ubican en el diagrama.
- ▶ Útiles para comparar dos conjuntos de datos en cuanto a su localización y dispersión

Asimetría y Curtosis

Coeficiente de asimetría (muestral) de Fisher

$$g_1 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^{3/2}} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{S^3}$$



Asimetría y Curtosis

Coeficiente de asimetría (muestral) de Fisher

$$g_1 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^{3/2}} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{S^3}$$

- Si $g_1 > 0$, la distribución es **asimétrica positiva** o a la derecha.

Asimetría y Curtosis

Coeficiente de asimetría (muestral) de Fisher

$$g_1 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^{3/2}} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{S^3}$$

- ▶ Si $g_1 > 0$, la distribución es **asimétrica positiva** o a la derecha.
- ▶ Si $g_1 < 0$, la distribución es **asimétrica negativa** o a la izquierda.

Asimetría y Curtosis

Coeficiente de asimetría (muestral) de Fisher

$$g_1 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^{3/2}} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^3}{S^3}$$

- ▶ Si $g_1 > 0$, la distribución es **asimétrica positiva** o a la derecha.
- ▶ Si $g_1 < 0$, la distribución es **asimétrica negativa** o a la izquierda.
- ▶ Si $g_1 = 0$, la distribución es **simétrica**.

Asimetría y Curtosis

Coeficiente de curtosis (muestral) de Fisher

$$g_2 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^2} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{S^4}$$

Asimetría y Curtosis

Coeficiente de curtosis (muestral) de Fisher

$$g_2 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^2} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{S^4}$$

- Si $g_2 > 3$, la distribución es **más apuntada y con colas más gruesas** que la normal (**leptocúrtica**).

Asimetría y Curtosis

Coeficiente de curtosis (muestral) de Fisher

$$g_2 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^2} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{S^4}$$

- ▶ Si $g_2 > 3$, la distribución es **más apuntada y con colas más gruesas** que la normal (**leptocúrtica**).
- ▶ Si $g_2 < 3$, la distribución es **menos apuntada y con colas menos gruesas** que la normal (**platicúrtica**).

Asimetría y Curtosis

Coeficiente de curtosis (muestral) de Fisher

$$g_2 = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{\left[\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right]^2} = \frac{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^4}{S^4}$$

- ▶ Si $g_2 > 3$, la distribución es **más apuntada y con colas más gruesas** que la normal (**leptocúrtica**).
- ▶ Si $g_2 < 3$, la distribución es **menos apuntada y con colas menos gruesas** que la normal (**platicúrtica**).
- ▶ Si $g_2 = 3$, la distribución tiene curtosis igual la de una distribución normal (**mesocúrtica**).